T1

May 28, 2021

1 Tarefa 1

MO432A - Aprendizado Supervisionado

> Aplicação de métodos de aprendizado supervisionado para resolver problemas de predição

Alunos: - Andreza - RA: 164213 - Gil - RA: 225323 - Yan - RA: 118982

2 Importando as bibliotecas

[63]:
```
import sklearn
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import ShuffleSplit, train_test_split
from sklearn.metrics import mean_absolute_error, mean_squared_error
```

3 Leitura dos dados

[64]:
```
df_original = pd.read_csv('solar-flare.csv', header = None, skiprows = 1, sep =␣
↪' ')
print("Dados")
print("Número de linhas: {}\nNúmero de colunas: {}".format(df_original.
↪shape[0], df_original.shape[1]))
```

```
Dados
Número de linhas: 1066
Número de colunas: 13
```

Impressão das primeiras e últimas amostras do conjunto de dados

[65]:
```
df_original.head(-10)
```

[65]:
```
      0  1  2   3   4   5   6   7   8   9   10  11  12
0     H  A  X   1   3   1   1   1   1   1   0   0   0
1     D  R  O   1   3   1   1   2   1   1   0   0   0
2     C  S  O   1   3   1   1   2   1   1   0   0   0
3     H  R  X   1   2   1   1   1   1   1   0   0   0
4     H  S  X   1   1   1   1   2   1   1   0   0   0
..   .. .. ..  ..  ..  ..  ..  ..  ..  ..  ..  ..  ..
1051  D  H  O   1   3   1   2   2   1   1   0   0   0
1052  E  A  I   2   2   1   2   2   1   1   0   0   0
1053  D  S  O   1   3   1   1   2   1   1   0   0   0
1054  H  S  X   1   1   1   1   1   1   1   0   0   0
1055  H  S  X   1   2   1   1   2   1   1   0   0   0

[1056 rows x 13 columns]
```

Para facilitar a manipulação dos dados, separamos a coluna composta por todos os dados em 13 colunas de nomes correspondentes a seus significados. O significado de cada valor foi retirado da fonte da base, disponível em https://archive.ics.uci.edu/ml/datasets/Solar+Flare

[66]:
```
df_original = df_original.rename(
                {0: "class_code", 1: "largest_spot_size", 2:␣
↪"spot_distribution",
                 3: "activity", 4: "evolution", 5: "24_flare_activity", 6:␣
↪"historically_complex",
                 7: "region_become_hcomplex", 8: "area", 9:␣
↪"largest_spot_area", 10: "c_class",
                 11: "m_class", 12: "x_class"}, axis='columns')

df_original.head(-10)
```

[66]:
```
     class_code largest_spot_size spot_distribution  activity  evolution  \
0             H                A                 X         1          3
1             D                R                 O         1          3
2             C                S                 O         1          3
3             H                R                 X         1          2
4             H                S                 X         1          1
...         ...              ...               ...       ...        ...
1051          D                H                 O         1          3
1052          E                A                 I         2          2
1053          D                S                 O         1          3
1054          H                S                 X         1          1
1055          H                S                 X         1          2

      24_flare_activity  historically_complex  region_become_hcomplex  area  \
0                     1                     1                       1     1
1                     1                     1                       2     1
2                     1                     1                       2     1
```

```
3                     1                     1                     1     1
4                     1                     1                     2     1
…                   …                     …                   …   …
1051                  1                     2                     2     1
1052                  1                     2                     2     1
1053                  1                     1                     2     1
1054                  1                     1                     1     1
1055                  1                     1                     2     1

      largest_spot_area  c_class  m_class  x_class
0                     1        0        0        0
1                     1        0        0        0
2                     1        0        0        0
3                     1        0        0        0
4                     1        0        0        0
…                   …      …        …        …
1051                  1        0        0        0
1052                  1        0        0        0
1053                  1        0        0        0
1054                  1        0        0        0
1055                  1        0        0        0

[1056 rows x 13 columns]
```

4 Conversão os atributos categóricos para numéricos

Convertemos as três primeiras colunas categóricas para numéricas utilizando a função get_dummies do panda.

[67]:
```
# Transforma três primeiras colunas de categóricas para numéricas
columns_categorical = df_original.columns[:3]
df_converted = pd.get_dummies(df_original, columns=columns_categorical)
column_order = [
        'class_code_B', 'class_code_C', 'class_code_D', 'class_code_E',␣
↪'class_code_F',
        'class_code_H', 'largest_spot_size_A', 'largest_spot_size_H',␣
↪'largest_spot_size_K',
        'largest_spot_size_R', 'largest_spot_size_S', 'largest_spot_size_X',␣
↪'spot_distribution_C',
        'spot_distribution_I', 'spot_distribution_O', 'spot_distribution_X',␣
↪'activity',
        'evolution', '24_flare_activity', 'historically_complex',␣
↪'region_become_hcomplex',
        'area', 'largest_spot_area', 'c_class', 'm_class', 'x_class']
df_converted = df_converted[column_order]
```

[68]:
```
columns_categorical
```

[68]:
```
Index(['class_code', 'largest_spot_size', 'spot_distribution'], dtype='object')
```

Imprimir primeiras e últimas linhas do conjunto após conversão dos atributos

[69]:
```
df_converted.head(-10)
```

[69]:

	class_code_B	class_code_C	class_code_D	class_code_E	class_code_F	\
0	0	0	0	0	0	
1	0	0	1	0	0	
2	0	1	0	0	0	
3	0	0	0	0	0	
4	0	0	0	0	0	
…	…	…	…	…	…	
1051	0	0	1	0	0	
1052	0	0	0	1	0	
1053	0	0	1	0	0	
1054	0	0	0	0	0	
1055	0	0	0	0	0	

	class_code_H	largest_spot_size_A	largest_spot_size_H	\
0	1	1	0	
1	0	0	0	
2	0	0	0	
3	1	0	0	
4	1	0	0	
…	…	…	…	
1051	0	0	1	
1052	0	1	0	
1053	0	0	0	
1054	1	0	0	
1055	1	0	0	

	largest_spot_size_K	largest_spot_size_R	…	activity	evolution	\
0	0	0	…	1	3	
1	0	1	…	1	3	
2	0	0	…	1	3	
3	0	1	…	1	2	
4	0	0	…	1	1	
…	…	…	…	…	…	
1051	0	0	…	1	3	
1052	0	0	…	2	2	
1053	0	0	…	1	3	
1054	0	0	…	1	1	
1055	0	0	…	1	2	

```
      24_flare_activity  historically_complex  region_become_hcomplex  area  \
0                     1                     1                       1     1
1                     1                     1                       2     1
2                     1                     1                       2     1
3                     1                     1                       1     1
4                     1                     1                       2     1
…                   …                     …                     …   …
1051                  1                     2                       2     1
1052                  1                     2                       2     1
1053                  1                     1                       2     1
1054                  1                     1                       1     1
1055                  1                     1                       2     1

      largest_spot_area  c_class  m_class  x_class
0                     1        0        0        0
1                     1        0        0        0
2                     1        0        0        0
3                     1        0        0        0
4                     1        0        0        0
…                   …      …        …        …
1051                  1        0        0        0
1052                  1        0        0        0
1053                  1        0        0        0
1054                  1        0        0        0
1055                  1        0        0        0

[1056 rows x 26 columns]
```

5 Centering and scaling

Convertemos os dados com a função StandarScaler do sklearn,estandarizando os dados ao remover a média e ajustar para variância unitária.

[70]:
```
X = df_converted.iloc[:, :-3]
y = df_converted.loc[:, 'c_class':'x_class']

X = StandardScaler().fit_transform(X)
print('X shape:', X.shape)
print('y shape:', y.shape)
```

```
X shape: (1066, 23)
y shape: (1066, 3)
```

6 PCA

Abaixo aplicamos PCA para reduzir a dimensionalidade dos dados. Plotamos a variância agregada para cada componente. Verificamos que com cerca de 16 componentes já adquirimos 100% da

variância. Para capturarmos 90% da variância dos dados, necessitamos selecionar 13 componentes, como demonstrado abaixo.

[71]:
```
pca = PCA().fit(X)
plt.plot(np.cumsum(pca.explained_variance_ratio_))
plt.xlabel('number of components', fontsize=16)
plt.xticks(range(0, 23),rotation=45)
plt.yticks(np.linspace(0, 1, 10, endpoint=True))
plt.ylabel('cumulative\nexplained variance', fontsize=16)
plt.title("\nScree plot of Variances\n", fontsize=18)
plt.show()
```

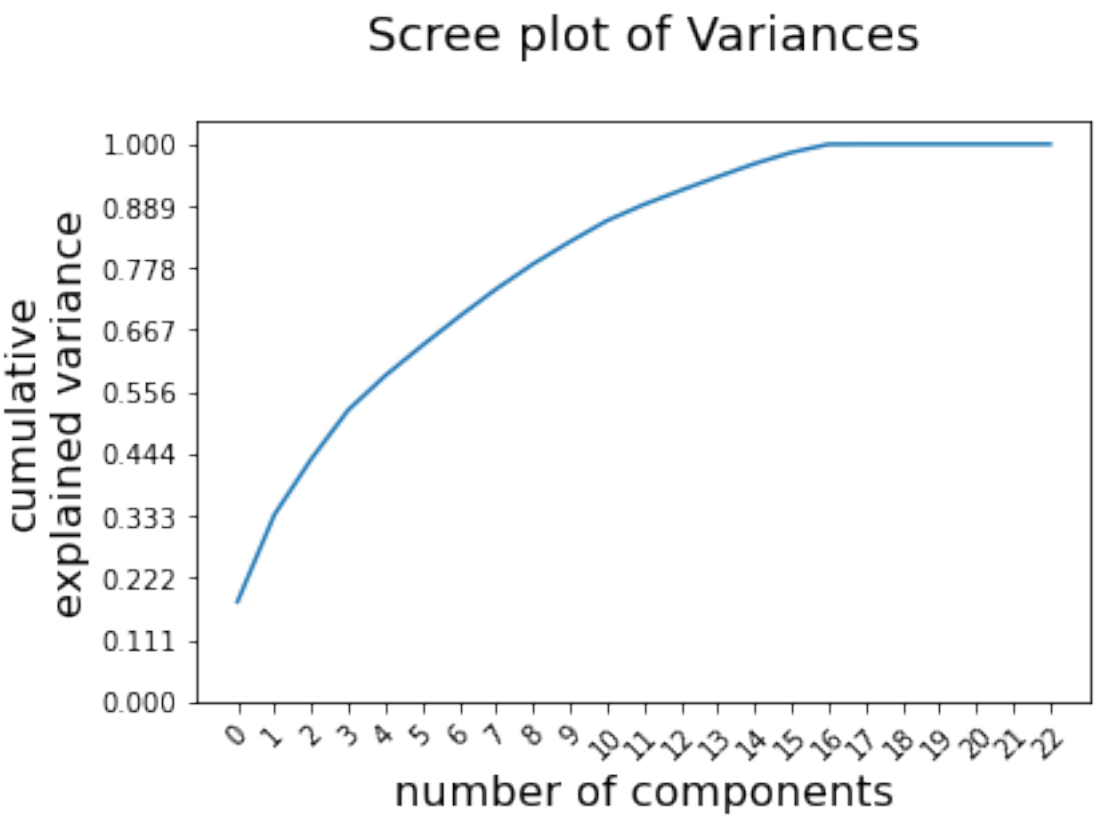

[72]:
```
pca = PCA(n_components = 0.9,  svd_solver = 'full' )
X_pca = pca.fit_transform(X)
print("Conjunto de dados após transformação PCA:")
print('X shape:', X_pca.shape)
print('y shape:', y.shape)
print('O número de componentes para 90% da variância é:', X_pca.shape[1])
```

```
Conjunto de dados após transformação PCA:
```

```
X shape: (1066, 13)
y shape: (1066, 3)
O número de componentes para 90% da variância é: 13
```

7 Validação cruzada e regressão linear

Separamos cada coluna de output para rodar as regressões lineares para cada output features, dado os input features com os 13 componentes do pca.

[73]:
```
# Separa as três colunas de target para as regressões separadas
y_c_class = y.iloc[:, 0]
y_m_class = y.iloc[:, 1]
y_x_class = y.iloc[:, 2]
```

7.0.1 Função para treinar modelo

[74]:
```
# Treina e avalia regressor para 5 interações
def train_evaluate_model(X, y):
    scores_rmse=[]
    scores_mae=[]
    scoring = ['neg_mean_squared_error','neg_mean_absolute_error']
    for i in range(5):
        # cria separação 70/30 (train/test)
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.
 ↪3)

        model = LinearRegression()
        # treina modelo
        model = model.fit(X_train, y_train)
        # avalia modelo
        y_pred = model.predict(X_test)
        mae = mean_absolute_error(y_test, y_pred,)
        rmse = mean_squared_error(y_test, y_pred, squared = False)
        print("iteração #{}\nRMSE: {:.5f} | MAE: {:.5f}".format(i, rmse, mae))
        scores_rmse.append(rmse)
        scores_mae.append(mae)
        print()
    print('MÉDIA DOS RMSE: {:.5f}'.format(np.mean(scores_rmse)))
    print('MÉDIA DOS MAE: {:.5f}'.format(np.mean(scores_mae)))
```

7.0.2 Fitting classe C

[76]:
```
print("Treinamentos e métricas para a predição da classe C")
train_evaluate_model(X, y_c_class)
```

```
Treinamentos e métricas para a predição da classe C
iteração #0
```

```
RMSE: 0.66547 | MAE: 0.39692

iteração #1
RMSE: 0.82047 | MAE: 0.43030

iteração #2
RMSE: 0.76146 | MAE: 0.43991

iteração #3
RMSE: 0.66767 | MAE: 0.36042

iteração #4
RMSE: 0.79191 | MAE: 0.41953

MÉDIA DOS RMSE: 0.74140
MÉDIA DOS MAE: 0.40942
```

7.0.3 Fitting classe M

[77]:
```
print("Treinamentos e métricas para a predição da classe M")
scores=train_evaluate_model(X, y_m_class)
```

```
Treinamentos e métricas para a predição da classe M
iteração #0
RMSE: 0.19172 | MAE: 0.08127

iteração #1
RMSE: 0.26139 | MAE: 0.09929

iteração #2
RMSE: 0.26112 | MAE: 0.09885

iteração #3
RMSE: 0.24737 | MAE: 0.08583

iteração #4
RMSE: 0.20636 | MAE: 0.09066

MÉDIA DOS RMSE: 0.23359
MÉDIA DOS MAE: 0.09118
```

7.0.4 Fitting classe X

[79]:
```
print("Treinamentos e métricas para a predição da classe X")
scores=train_evaluate_model(X, y_x_class)
```

```
Treinamentos e métricas para a predição da classe X
iteração #0
```

```
RMSE: 0.13266 | MAE: 0.01609

iteração #1
RMSE: 0.05998 | MAE: 0.02504

iteração #2
RMSE: 0.06376 | MAE: 0.01332

iteração #3
RMSE: 0.11806 | MAE: 0.01511

iteração #4
RMSE: 0.08327 | MAE: 0.02099

MÉDIA DOS RMSE: 0.09155
MÉDIA DOS MAE: 0.01811
```

8 Conclusões

Percebemos que para duas classes, em uma das interações de treinamento e teste do modelo temos um erro enorme. Isso acabou elevando a média do erro, tanto para a métrica de RMSE quando a do MAE. Quando rodamos novamente o código, aí só obtivemos erros baixos em todas as classes preditas. Isso é um indicativo que uma regressão linear talvez não sirva para a previsão das classes.